

Contents

1 MiniMax H3 + ComfyUI — практический гайд	5
1.1 Содержание	5
1.2 Что используем	5
1.3 Наш подход	6
1.4 Актуальные официальные файлы	6
1.5 Важно	6
1.6 Основные ссылки	6
1.7 Workflow templates	6
2 01 — База: MiniMax H3 простыми словами	7
2.1 Цель	7
2.2 1. Что мы строим	7
2.3 2. Компоненты	7
2.3.1 ComfyUI	7
2.3.2 MiniMax H3	7
2.3.3 Qwen3-VL-32B	7
2.3.4 Video VAE	7
2.3.5 Audio VAE	7
2.4 3. VRAM и RAM	7
2.5 4. Квантизация	7
2.6 5. Offload	8
2.7 6. FL2VA	8
2.8 7. Ref2VA	8
2.9 8. Почему I2V важнее T2V для VN	8
2.10 9. Steps, seed, resolution, frames	8
2.11 10. Как сравнивать модели честно	8
2.12 11. Что оцениваем	8
2.13 12. Наши пять правил	9
3 02 — Установка MiniMax H3 от нуля	10
3.1 Цель	10
4 1. Перед установкой	10
5 2. Версия ComfyUI	10
6 3. Базовые папки	10
7 4. Официальные VAE	10
8 5. Официальный FL2VA baseline	11
9 6. Официальный Ref2VA	11
10 7. Qwen H3 encoder	11
11 8. Первый workflow	11
12 9. Как импортировать workflow	12
13 10. Первый render	12
14 11. Первый prompt	12
15 12. Если модель не отображается	12
16 13. Если CUDA OOM	13
17 14. Если RAM почти закончилась	13
18 15. Установка community INT4	13

1916. W4A8 — отдельная установка	13
19.0.1Важное ограничение	14
2017. SVDQuant	14
2118. GGUF	14
2219. Правильная структура установки	14
2320. Версии фиксируем	15
2421. Что устанавливаем в каком порядке	15
2522. Если что-то не работает	15
2603 — Модели, квантизация и варианты H3	17
26.1Зачем нужен этот файл	17
271. Официальный baseline	17
27.0.1Основные официальные файлы	17
27.0.2Дата	17
282. DmitryDB — большая коллекция ComfyUI-квантизаций	18
28.0.1Текущий статус	18
28.0.2Что искать внутри	18
293. Merseker — INT4 ConvRot	18
29.0.1Файлы	18
29.0.2Дата / версия	18
29.0.3Для нашей 3070 Ti	19
304. Abiray — NVFP4 / INT4 / INT8 ConvRot	19
30.0.1Статус	19
30.0.2Для нас	19
315. starsfriday — W4A8	19
31.0.1Дата / версия	19
31.0.2Что означает W4A8	19
326. GGUF — отдельная группа	19
32.0.1Найденные актуальные H3 GGUF	20
32.0.2Варианты	20
337. FP8	20
33.0.1Для нашей 3070 Ti	20
348. NVFP4 pruned	20
359. INT4 Mixed ConvRot	21
35.0.1Статус	21
3610. Turbo LoRA	21
36.0.1Что это	21
3711. DynTime / sQKV	21
3812. MLX	21
38.0.1Но для нас	22
3913. Большая актуальная карта H3 на 19.08.2026	22
4014. Что означает «последняя версия»	22
4115. Почему даты особенно важны для H3	23

4216. Правило для будущих обновлений	23
4317. Официальные источники	24
43.1 Community	24
4418. Важное уточнение про «все модели»	24
4504 — Workflow: I2V, T2V, First/Last Frame и Ref2VA	25
45.11. Выбор режима	25
462. I2V — основной pipeline	25
473. Как подготовить исходный render	25
484. Prompt для I2V	25
495. Хороший первый пример	26
506. Почему не надо писать слишком длинный prompt	26
517. First Frame	26
528. Last Frame	27
539. First + Last Frame	27
5410. T2VA	27
5511. Ref2VA	27
55.0.1 Пример логики	27
5612. Роли референсов	28
5713. ref_image_size	28
5814. Sampler / Scheduler	28
5915. Аудио	28
6016. Разрешение	28
6117. Длительность	29
6218. Настройки каждой quant разные	29
6319. Production workflow №1 — персонаж	29
6420. Production workflow №2 — identity-heavy	29
6521. Production workflow №3 — переход	30
6622. Production workflow №4 — фон	30
6723. Рекомендуемая библиотека preset	30
6805 — Экспериментальная лаборатория	31
68.1 Цель	31
691. Золотое правило	31
702. Qwen 8-bit vs 4-bit	31
713. H3: INT8 → W4 → INT4	31
724. INT4Q / INT4BQ	32
735. W4A8	32

746. SVDQuant	32
757. GGUF	32
768. Turbo LoRA	33
779. DynTime / sQKV	33
7810. Тест идентичности	33
7911. Тест сложного движения	33
8012. Тест длинного видео	34
8113. Тест разрешения	34
8214. Система оценки	34
8315. PASS/FAIL	34
8416. Три production-профиля	35
84.0.1FAST	35
84.0.2BALANCED	35
84.0.3QUALITY	35
84.0.4EXPERIMENTAL	35
8517. Как фиксировать эксперимент	35
8618. Почему один ролик недостаточен	35
8719. Финальный вопрос лаборатории	35
8806 — Полный benchmark на RTX 3070 Ti 8 GB + 64 GB RAM	36
88.1Цель	36
891. Карточка каждого теста	36
902. Почему нельзя копировать чужую скорость	36
913. A1 — официальный baseline	37
924. A2/A3 — Qwen	37
935. B — H3	37
946. VRAM	38
957. RAM	38
968. Время	38
979. Качество 0-10	38
9810. Quality/Time	39
9911. Матрица	39
1002. Длинные ролики	39
1013. Разрешение	39
1024. OOM protocol	39
1035. Missing model	40
1046. Missing node	40

1057. Production-ready	40
1068. Финальные профили	40
106.0. E AST	40
106.0. B ALANCED	40
106.0. Q UALITY	40
106.0. E XPERIMENTAL	40
1079. Production benchmark	41
1087 — Сверка предыдущих чатов: стыковки и нестыковки	42
108.1. Что подтверждается и сохраняется	42
108.1. Железо	42
108.1. План Qwen	42
108.1. План H3	42
108.1. Главный production-режим	42
109. Нестыковка №1 — «убрать 16 версии»	42
110. Нестыковка №2 — ComfyUI 0.28 против H3	42
111. Нестыковка №3 — «Qwen 3.6 / 3.8»	43
112. Нестыковка №4 — Qwen и H3	43
113. Нестыковка №5 — размер файла ≠ необходимая VRAM	43
114. Нестыковка №6 — W4, INT4 и GGUF Q4	43
115. Нестыковка №7 — NVFP4	43
116. Нестыковка №8 — W4A8	44
117. Что исправлено в текущем репозитории	44
118. Итоговая согласованная стратегия	44
118. Финальный критерий	44
119. Что пока нельзя утверждать без реального теста	45

1 MiniMax H3 + ComfyUI — практический гайд

Цель: локальная генерация видео для 3D Visual Novel.

ПК: RTX 3070 Ti 8 GB VRAM + 64 GB RAM.

Статус документа: рабочая база, обновляется по мере проверки моделей и реальных тестов на RTX 3070 Ti.

1.1 Содержание

1. База
2. Установка
3. Модели и квантизации
4. I2V / T2V / Ref2VA
5. Эксперименты
6. Тестирование на RTX 3070 Ti

1.2 Что используем

- **MiniMax H3** — основная видео+аудио модель.
- **Qwen3-VL-32B** — текстовый/визуальный encoder для H3.
- **Video VAE** — декодирование видео.

- **Audio VAE** — декодирование аудио.
- **ComfyUI** — интерфейс и workflow.

1.3 Наш подход

Не ищем самую большую модель. Ищем **лучшее качество за приемлемое время** на 8 GB VRAM.

Порядок тестов:

Qwen 8-bit → Qwen 4-bit → H3 INT8/W4/INT4 → Ref2VA → экспериментальные варианты → GGUF

1.4 Актуальные официальные файлы

Comfy-Org сейчас публикует для H3 FL2VA и Ref2VA в BF16, INT8 ConvRot и pruned INT8 ConvRot, а также Qwen3-VL-32B в BF16, INT8 ConvRot и NVFP4/AWQ. Также опубликованы два VAE. См. [официальный репозиторий Comfy-Org/MiniMax-H3](#).

1.5 Важно

BF16-версии огромны и не являются нашей первой целью на 8 GB. Community INT4/W4 варианты тестируем отдельно. GGUF — отдельный формат/экосистема и не равен обычному safetensors workflow.

1.6 Основные ссылки

- [ComfyUI](#)
- [Comfy-Org MiniMax H3](#)
- [MiniMaxAI MiniMax H3](#)
- [DmitryDB H3 ComfyUI Quants](#)
- [Mermerk INT4 ConvRot](#)
- [molbal H3 GGUF](#)
- [leejet H3 GGUF](#)

1.7 Workflow templates

- [I2V](#)
- [T2V](#)
- [R2V](#)

2 01 — База: MiniMax H3 простыми словами

2.1 Цель

Этот документ объясняет H3 с нуля и задаёт правила наших тестов на **RTX 3070 Ti 8 GB + 32 GB RAM**.

2.2 1. Что мы строим

3D render → ComfyUI → MiniMax H3 → video/audio

Главный режим для нашей Visual Novel — **I2V**: готовый рендер превращается в движущийся клип. H3 также поддерживает T2V/T2VA и Ref2VA. Community документация указывает до 2K и до 15 секунд, но фактические пределы зависят от workflow и памяти.

2.3 2. Компоненты

2.3.1 ComfyUI

Конструктор workflow. Здесь соединяются загрузка изображения, prompt, Qwen, H3, VAE, sampler и сохранение видео.

2.3.2 MiniMax H3

Основной генератор видео и аудио.

2.3.3 Qwen3-VL-32B

H3-специализированный encoder на базе Qwen3-VL-32B. В официальном ComfyUI-пакете есть отдельные варианты encoder. Не путать с обычной Qwen-моделью для чата.

2.3.4 Video VAE

minimax_h3_video_vae_fp16.safetensors — переводит видео-латенты в кадры.

2.3.5 Audio VAE

minimax_h3_audio_vae_fp32.safetensors — работает с аудио-латентом.

2.4 3. VRAM и RAM

У нас:

- RTX 3070 Ti — 8 GB VRAM;
- **32 GB RAM**.

VRAM быстрее, но маленькая. RAM медленнее, зато её больше. Поэтому H3 на нашем ПК будет зависеть от offload.

больше offload → меньше требований к VRAM → больше обмена → ниже скорость.

Это нормально: пользовательский приоритет — **качество/время**, а не максимальная скорость.

2.5 4. Квантизация

Квантизация уменьшает точность хранения весов.

Условно:

- BF16 — очень большой вариант;
- INT8 — меньше;
- INT4 — ещё меньше.

Но INT4, W4 и GGUF Q4 — не одно и то же. У них могут быть разные loaders, kernels и требования.

2.6 5. Offload

Offload переносит часть модели/нагрузки из VRAM в RAM/CPU. Для 8 GB это один из главных способов запускать крупные варианты. Цена — скорость.

2.7 6. FL2VA

FL2VA = first/last-frame-to-video/audio.

В зависимости от входов можно использовать:

- 0 изображений — T2V/T2VA;
- 1 изображение — первый или последний кадр;
- 2 изображения — первый + последний кадр.

2.8 7. Ref2VA

Ref2VA — отдельный reference-conditioned режим. В актуальном workflow используются отдельные reference inputs; community документация описывает изображения, видео и аудиореференсы. Это особенно интересно для сохранения персонажа.

2.9 8. Почему I2V важнее T2V для VN

T2V должна придумать персонажа и сцену.

I2V получает наш готовый 3D-рендер, поэтому уже зафиксированы:

- лицо;
- тело;
- одежда;
- интерьер;
- свет;
- композиция.

H3 нужно в основном создать движение.

2.10 9. Steps, seed, resolution, frames

Steps — число итераций генерации.

Seed — число случайности, которое помогает повторять эксперимент.

Resolution — размер кадра.

Frames — количество кадров.

Все четыре параметра влияют на время/память. На benchmark меняем только один параметр за раз.

2.11 10. Как сравнивать модели честно

Плохой тест:

новый H3 + новый Qwen + новый prompt + новое разрешение.

Хороший:

один H3 + один Qwen + один prompt + один seed, меняется только H3.

Для Qwen-теста наоборот фиксируем H3 и меняем только Qwen.

2.12 11. Что оцениваем

1. лицо;
2. идентичность персонажа;
3. руки;

4. волосы;
5. одежду;
6. движение;
7. камеру;
8. фон;
9. аудио;
10. время;
11. VRAM;
12. RAM;
13. стабильность от клипа к клипу.

2.13 12. Наши пять правил

1. Сначала запускаем baseline.
2. Не скачиваем всё подряд в одну папку.
3. Для каждой квантизации используем её собственный loader, если он требуется.
4. Не считаем размер файла равным пиковому VRAM.
5. Если точное требование не подтверждено автором сборки — пишем TBD, а не угадываем.

3 02 — Установка MiniMax H3 от нуля

3.1 Цель

Получить первый рабочий H3 I2V workflow на **RTX 3070 Ti 8 GB + 64 GB RAM**, а затем перейти к Qwen 8/4-bit и community quant.

Дата гайда: **19.08.2026**. H3 community сейчас обновляется очень быстро, поэтому перед каждой установкой сверяем README и commit.

4 1. Перед установкой

Не удаляй рабочий ComfyUI.

Не меняй Python вручную, если ComfyUI уже запускается.

Сначала проверяем текущую установку, затем обновляем только то, что действительно требуется.

Официальный ComfyUI:

<https://github.com/Comfy-Org/ComfyUI>

5 2. Версия ComfyUI

Для современных H3 community workflows ориентир — **ComfyUI 0.30.0+**. Некоторые экспериментальные сборки тестировались на конкретных версиях и могут требовать более новые или фиксированные версии.

Правило:

Если README конкретной модели говорит `tested on X`, для первого теста используем X или более новую совместимую версию.

Не считаем версию 0.30.0 универсальной гарантией для всех будущих H3 quant.

6 3. Базовые папки

Обычно:

```
ComfyUI/
├── models/
│   ├── diffusion_models/
│   ├── text_encoders/
│   └── vae/
└── custom_nodes/
```

Если конкретный loader требует `models/unet`, следуем его README.

7 4. Официальные VAE

Источник:

<https://huggingface.co/Comfy-Org/MiniMax-H3>

Файлы:

minimax_h3_video_vae_fp16.safetensors
minimax_h3_audio_vae_fp32.safetensors

Положить:

ComfyUI/models/vae/

8 5. Официальный FL2VA baseline

Файл:

minimax_h3_fl2va_pruned_int8_convrot.safetensors

Путь:

ComfyUI/models/diffusion_models/

Источник:

<https://huggingface.co/Comfy-Org/MiniMax-H3>

9 6. Официальный Ref2VA

Файл:

minimax_h3_ref2va_pruned_int8_convrot.safetensors

Путь тот же:

ComfyUI/models/diffusion_models/

Но **не подключаай его вместо FL2VA в первом I2V workflow**. Это отдельный pipeline.

10 7. Qwen H3 encoder

Официальный baseline:

qwen3vl_32b_minimax_h3_nvfp4_awq.safetensors

Путь:

ComfyUI/models/text_encoders/

Важно: это специальный H3 encoder. Не скачивай обычный Qwen3-VL из случайного репозитория и не рассчитывай, что он автоматически заменит этот файл.

Официальный H3 репозиторий также содержит BF16 и INT8 ConvRot encoder-варианты. Для 8 GB мы сначала проверяем более компактные варианты.

11 8. Первый workflow

Официальный I2V:

https://github.com/Comfy-Org/workflow_templates/blob/main/templates/video_minimax_h3_i2v.json

Официальный T2V:

https://github.com/Comfy-Org/workflow_templates/blob/main/templates/video_minimax_h3_t2v.json

Официальный R2V:

https://github.com/Comfy-Org/workflow_templates/blob/main/templates/video_minimax_h3_r2v.json

Сначала используем **I2V**.

12 9. Как импортировать workflow

1. Скачать JSON.
2. Открыть ComfyUI.
3. Перетащить JSON в окно ComfyUI.
4. Проверить названия моделей.
5. Загрузить исходную картинку.
6. Ввести простой prompt.
7. Запустить Queue.

Если ComfyUI сообщает о missing nodes, сначала выясняем название node и источник workflow.

13 10. Первый render

Для первого теста:

- 1 персонаж;
- готовый 3D render;
- 4-5 секунд;
- умеренное разрешение;
- простой prompt;
- одно основное действие;
- фиксированный seed.

Цель — не красота, а **первый успешный запуск**.

14 11. Первый prompt

Cinematic medium shot of a woman standing in a modern bedroom at night.
She slowly turns her head toward the camera.
Her hair and clothing move subtly and naturally.
The camera performs a very slow push-in.
Warm practical lighting and a soft cool rim light.
Quiet bedroom ambience and subtle fabric movement.

Не добавляй сразу десять действий.

15 12. Если модель не отображается

Проверь:

ComfyUI/models/diffusion_models/
ComfyUI/models/text_encoders/
ComfyUI/models/vae/

Имена файлов должны быть правильными.

После добавления файлов перезапусти ComfyUI.

16 13. Если CUDA OOM

Делай по порядку:

1. закрыть другие GPU-приложения;
2. уменьшить разрешение;
3. уменьшить длительность;
4. проверить offload;
5. использовать более лёгкий quant;
6. проверить loader.

Не меняй одновременно H3 + Qwen + workflow + sampler.

17 14. Если RAM почти закончилась

64 GB — большой запас, но не бесконечный.

Проверь:

- Windows Task Manager;
- pagefile;
- другие приложения;
- объём offload;
- размер конкретного checkpoint.

Если Windows начинает активно использовать pagefile, генерация может стать экстремально медленной.

18 15. Установка community INT4

После успешного baseline:

Источник:

<https://huggingface.co/Merserk/MiniMax-H3-INT4-ConvRot>

Для начала интересен pruned FL2VA.

Не заменяем старый baseline: сохраняем оба файла.

Пример:

```
models/diffusion_models/  
├─ minimax_h3_fl2va_pruned_int8_convrot.safetensors  
└─ minimax_h3_fl2va_pruned_int4_convrot.safetensors
```

19 16. W4A8 — отдельная установка

Источник:

<https://huggingface.co/starsfriday/MiniMax-H3-w4a8>

Loader:

<https://github.com/starsFriday/ComfyUI-W4A8-Loader>

Автор указывает отдельный custom loader и comfy-kitchen. Обычный diffusion loader использовать нельзя.

Checkpoint:

minimax_h3_fl2va_pruned_w4a8_mixed.safetensors
minimax_h3_ref2va_pruned_w4a8_mixed.safetensors

Заявленный размер: **12.54 GB**.

19.0.1 Важное ограничение

README loader указывает Linux, NVIDIA SM80+, Python 3.10+, CUDA 12.8+ и соответствующий PyTorch/toolkit; Windows installer не поддерживается. Поэтому на Windows это **не первый вариант**, даже несмотря на то, что RTX 3070 Ti архитектурно относится к Ampere/SM86.

20 17. SVDQuant

Источник:

<https://huggingface.co/Aero-Ex/MiniMax-H3-SVDQuant>

Это отдельная экспериментальная W4A4/SVDQuant toolchain.

Автор заявляет около **11.1 GB** для rank-64 act-aware варианта и указывает INT8 activation compute как интересный вариант для Ampere.

Ставим после обычного INT4.

21 18. GGUF

GGUF устанавливается отдельно.

Например:

<https://huggingface.co/molbal/MiniMax-H3-GGUF>

molbal указывает Q4_0/Q8_0/Q8_CR/U16G и отдельные требования для Q8_CR/U16G.

Не смешивать GGUF loader разных авторов.

22 19. Правильная структура установки

Не складывай все эксперименты в одну заменяемую папку без понимания loader.

Минимум:

```
ComfyUI/models/  
├── diffusion_models/  
│   ├── official/  
│   ├── int4/  
│   └── experimental/  
├── text_encoders/  
└── vae/
```

Если ComfyUI не видит вложенные папки, используй его стандартные пути/extra_model_paths вместо самовольного изменения структуры.

23 20. Версии фиксируем

Перед каждым экспериментом записываем:

Date:
ComfyUI:
Python:
PyTorch:
CUDA:
GPU:
H3 repository:
H3 commit:
H3 file:
Qwen repository:
Qwen commit:
Qwen file:
Loader repository:
Loader commit:
Workflow commit:

Это позволяет повторить рабочую сборку даже после обновлений.

24 21. Что устанавливаем в каком порядке

ComfyUI
↓
VAE
↓
официальный Qwen H3 encoder
↓
официальный FL2VA INT8
↓
официальный I2V workflow
↓
первый ролик
↓
Qwen 8-bit / 4-bit
↓
INT4
↓
W4
↓
Ref2VA
↓
SVDQuant / W4A8
↓
GGUF
↓
Turbo LoRA / DynTime / другие эксперименты

25 22. Если что-то не работает

Сохраняй полный текст ошибки из консоли ComfyUI.

Не пересказывай ошибку своими словами, если можешь скопировать её полностью.

Для диагностики нужны:

- ошибка;

- версия ComfyUI;
- модель;
- workflow;
- Windows/Linux;
- VRAM;
- RAM.

26 03 — Модели, квантизация и варианты H3

26.1 Зачем нужен этот файл

Здесь собираем карту MiniMax H3: официальные варианты, community-квантизации и экспериментальные сборки.

Важно: у Hugging Face-моделей обычно нет классических версий v1.0 / v2.0. Поэтому в этом гайде под «последней версией» фиксируем **последний наблюдаемый commit / состояние репозитория на дату проверки**. Если автор использует release/tag, он будет указан отдельно.

Дата текущего среза: 19.08.2026.

Даты обновления ниже — это состояние, которое удалось подтвердить при проверке 19.08.2026. Community-модели могут обновиться буквально через несколько часов.

27 1. Официальный baseline

Актуальная Comfy-Org упаковка содержит FL2VA и Ref2VA в нескольких вариантах точности, Qwen3-VL-32B для H3 и два VAE. Официальный H3 workflow — наша отправная точка.

27.0.1 Основные официальные файлы

H3 FL2VA:
minimax_h3_fl2va_pruned_int8_convrot.safetensors

H3 Ref2VA:
minimax_h3_ref2va_pruned_int8_convrot.safetensors

Qwen:
qwen3vl_32b_minimax_h3_nvfp4_awq.safetensors

Video VAE:
minimax_h3_video_vae_fp16.safetensors

Audio VAE:
minimax_h3_audio_vae_fp32.safetensors

27.0.2 Дата

Репозиторий	Последнее наблюдаемое обновление	Последняя версия/состояние
Comfy-Org/MiniMax-H3	19.08.2026 — обновлялся в последние часы	main / текущий HEAD на дату проверки
MiniMaxAI/MiniMax-H3	19.08.2026 — обновлялся в последние часы	main / текущий HEAD на дату проверки

У официальной модели нет опубликованной семантической версии вроде 1.2.0; поэтому в гайде используем дату + commit, когда нужна точная воспроизводимость. Поисковый индекс Hugging Face на 19.08 показывает оба официальных репозитория как обновлённые в течение текущих суток.

28 2. DmitryDB — большая коллекция ComfyUI-квантизаций

Репозиторий: <https://huggingface.co/DmitryDB/MiniMax-H3-ComfyUI-Quants>

Это одна из главных коллекций для нашего исследования. Автор отдельно подчёркивает, что это **community conversions**, а не официальные релизы MiniMax/Comfy-Org. Репозиторий содержит FL2VA и Ref2VA, а также разные quant-профили.

28.0.1 Текущий статус

- Репозиторий: main
- История: **77 commits** на момент проверки
- Последний наблюдаемый commit: 06aba48
- Сообщение последнего commit: **Remove failed W4 and W8W4 experiments**
- Последнее обновление: **19.08.2026 / текущее обновление**, по текущему состоянию Hugging Face

Последний commit важен: из коллекции были удалены неудачные W4 и W8W4 эксперименты. Поэтому старые сообщения сообщества о наличии этих конкретных файлов нельзя автоматически считать актуальными.

28.0.2 Что искать внутри

- FL2VA
- Ref2VA
- INT8
- W4
- W8/W4
- NVFP4
- другие community profiles

Статус для нашей 3070 Ti: основной каталог для проверки, но не скачиваем всё подряд.

29 3. Merseerk — INT4 ConvRot

Репозиторий: <https://huggingface.co/Merseerk/MiniMax-H3-INT4-ConvRot>

Это отдельная community INT4-сборка для ComfyUI. README прямо указывает, что это low-memory INT4 ConvRot и рекомендует pruned checkpoint для 12 GB GPU, с offload и 32 GB+ RAM.

29.0.1 Файлы

Файл	Размер	Назначение
minimax_h3_fl2va_pruned_int4_convrot.safetensors	11.3 GB	FL2VA
minimax_h3_ref2va_pruned_int4_convrot.safetensors	11.3 GB	Ref2VA
minimax_h3_fl2va_int4_convrot.safetensors	17.9 GB	полный FL2VA
minimax_h3_ref2va_int4_convrot.safetensors	17.9 GB	полный Ref2VA
qwen3vl_32b_minimax_h3_int4_convrot.safetensors	15.0 GB	Qwen INT4

Источник размеров и состава файлов: README и файловое дерево репозитория.

29.0.2 Дата / версия

- История: **7 commits** на проверенном состоянии.
- Последний наблюдаемый commit: **3c167bc**.
- Последнее изменение README было зафиксировано **19.08.2026**, примерно за несколько часов до проверки.
- Семантической версии нет: актуальность определяем по commit 3c167bc.

Hugging Face показывает этот commit как verified и указывает обновление README.

29.0.3 Для нашей 3070 Ti

Очень интересен **pruned INT4**, но не считаем его гарантированно запускаемым только по названию «8 GB». Автор ориентируется на 12 GB GPU. Мы будем проверять фактический запуск с 64 GB RAM отдельно.

30 4. Abiray — NVFP4 / INT4 / INT8 ConvRot

Репозиторий: <https://huggingface.co/Abiray/Minimax-H3-nvfp4-INT4-INT8-Convrot>

На 19.08.2026 это один из самых активно обновляемых community-проектов H3. Hugging Face показывает последнее обновление **19.08.2026** (примерно в пределах текущих суток).

30.0.1 Статус

- Последнее обновление: **19.08.2026**
- Семантическая версия: **не заявлена**
- Точная версия: использовать текущий main commit на момент скачивания
- Категория: NVFP4 / INT4 / INT8 / ConvRot

30.0.2 Для нас

Интересный экспериментальный каталог, но **NVFP4 не равен обычному INT4**. Нельзя автоматически предполагать совместимость с RTX 3070 Ti. Проверяем loader/backend и требования README перед установкой.

31 5. starsfriday — W4A8

Репозиторий: <https://huggingface.co/starsfriday/MiniMax-H3-w4a8>

Это отдельная экспериментальная ветка W4A8.

31.0.1 Дата / версия

- Последнее наблюдаемое обновление: **19.08.2026**.
- Семантической версии нет.
- Используем текущий main commit.

Hugging Face относит этот репозиторий к Image-Text-to-Video и показывает обновление в течение последних суток.

31.0.2 Что означает W4A8

W4 = веса 4-bit

A8 = активации 8-bit

Это mixed-precision подход.

Для 3070 Ti: эксперимент. Не ставим первым.

32 6. GGUF — отдельная группа

GGUF нельзя смешивать с обычными safetensors INT4/W4.

Это другой формат и другая экосистема загрузки.

32.0.1 Найденные актуальные H3 GGUF

Репозиторий	Последнее обновление на 19.08.2026	Статус
realrebelai/MiniMax-H3-GGUFs	19.08.2026 , обновлялся в течение текущих часов	актуальный community GGUF
Abiray/MiniMax-H3-GGUF	19.08.2026 , обновлялся в течение текущих часов	актуальный community GGUF
vantagewithai/MiniMax-H3-comfyUI-GGUF	18-19.08.2026 , обновлён примерно 1-2 дня назад	ComfyUI GGUF
molbal/MiniMax-H3-GGUF	18-19.08.2026 , обновлён примерно сутки назад	GGUF
leejet/MiniMax-H3-GGUF	18-19.08.2026 , обновлён примерно сутки назад	GGUF
Abiray/MiniMax-H3-Pruned-GGUF	16.08.2026 , примерно 3 дня назад	pruned GGUF

Hugging Face показывает эти репозитории среди актуальных H3 image-to-video/text-to-video моделей.

32.0.2 Варианты

В зависимости от конкретного репозитория встречаются:

Q2
Q3
Q4
Q5
Q6
Q8

Важно: Q4 здесь не означает автоматически то же самое, что W4 или INT4.

33 7. FP8

Отдельно обнаружен community-вариант:

rzgar/minimax_h3_fl2va_fp8_e4m3fn

Hugging Face показывает его как Image-to-Video и обновлённый **19.08.2026**, примерно в течение последних часов на момент проверки.

33.0.1 Для нашей 3070 Ti

Интересный эксперимент, но не первый кандидат из-за 8 GB VRAM.

34 8. NVFP4 pruned

coolthor/MiniMax-H3-pruned-NVFP4

По текущему индексу Hugging Face обновлён **19.08.2026**.

Это отдельная NVFP4/pruned ветка. Не смешиваем её с INT4 ConvRot.

35 9. INT4 Mixed ConvRot

tsolful/Minimax_H3_INT4MixedConvRot

По индексу Hugging Face обновлён примерно **18.08.2026** (около 1–2 суток в зависимости от индекса).

35.0.1 Статус

Экспериментальный community quant.

Добавляем в лабораторию, но не делаем первым запуском.

36 10. Turbo LoRA

Обнаружены актуальные H3 Turbo LoRA-проекты, например:

- Abiray/MiniMax-H3-Turbo-Lora-Pruned-ComfyUI
- larryvrh/MiniMax-H3-Turbo-Lora
- drbaph/MiniMax-H3-Turbo-Lora-ComfyUI

На 19.08.2026 эти репозитории активно обновляются. Hugging Face показывает Abiray/MiniMax-H3-Turbo-Lora-Pruned-ComfyUI обновлённым **19.08.2026**, а другие Turbo LoRA — также в течение последних суток.

36.0.1 Что это

Это не отдельная базовая H3-квантизация.

LoRA предназначена для ускорения/изменения поведения базового workflow.

Тестируем после стабильного baseline.

37 11. DynTime / sQKV

Обнаружены community-варианты:

- DmitryDB/MiniMax-H3-DynTime-sQKV
- DmitryDB/MiniMax-H3-10Eros-Max-DT-sQKV

На 19.08.2026 оба активно обновлялись в течение последних суток.

Это уже не просто «ещё один Q4». Это отдельные экспериментальные модификации/сборки.

Добавляем в экспериментальный раздел.

38 12. MLX

Обнаружены:

- pipenetwork/MiniMax-H3-MLX-8bit
- pipenetwork/MiniMax-H3-MLX-6bit
- pipenetwork/MiniMax-H3-MLX-bf16
- ddalcu/MiniMax-H3-FL2VA-MLX-Serve-8bit
- ddalcu/MiniMax-H3-FL2VA-MLX-Serve-4bit

На 19.08.2026 они обновляются очень активно.

38.0.1 Но для нас

MLX не является приоритетом, потому что мы используем NVIDIA RTX 3070 Ti, а MLX ориентирован прежде всего на Apple Silicon.

Оставляем в каталоге, но не тратим время на него сейчас.

39 13. Большая актуальная карта НЗ на 19.08.2026

Вариант	Тип	Последнее обновление	Версия	Для 3070 Ti	Приоритет
Official FL2VA pruned INT8	safetensors	19.08.2026	current main	△	□□□□□
Official Ref2VA pruned INT8	safetensors	19.08.2026	current main	△	□□□□
DmitryDB Quants	mixed	19.08.2026	06aba48	△	□□□□□
Mermerk pruned INT4	INT4 ConvRot	19.08.2026	3c167bc	△	□□□□□
Abiray NVFP4/INT4/INT8	mixed	19.08.2026	current main	□	□□□
tsolful INT4MixedConvRot	INT4 mixed	~18.08.2026	current main	□	□□□
starsfriday W4A8	W4A8	~19.08.2026	current main	□	□□□
W4A8 rzgar FP8	FP8	19.08.2026	current main	□	□□
E4M3FN coolthor pruned NVFP4	NVFP4	19.08.2026	current main	□	□□
GGUF	GGUF	18-19.08.2026	зависит от repo	□	□□□
Turbo LoRA	LoRA	19.08.2026	current main	□	□□□
DynTime/sQKV	experimental	18-19.08.2026	current main	□	□□
MLX 4/6/8bit	MLX	18-19.08.2026	current main	□	□

□ = нельзя честно обещать совместимость без проверки конкретного loader/backend.

40 14. Что означает «последняя версия»

Для Hugging Face это важно.

Например:

Repository

↓

main

↓

commit 3c167bc

↓

последнее состояние файлов

Если автор не создаёт releases/tags, **commit** является лучшим способом зафиксировать конкретное состояние.

Поэтому для финальных инструкций мы будем записывать:

Дата проверки: 19.08.2026

Repository: Merseker/MiniMax-H3-INT4-ConvRot

Commit: 3c167bc

Так через месяц можно понять, какую именно версию мы тестировали.

41 15. Почему даты особенно важны для H3

H3 community сейчас развивается очень быстро.

На одном и том же поисковом индексе одновременно появляются новые:

- INT4;
- NVFP4;
- GGUF;
- Turbo LoRA;
- FP8;
- W4A8;
- mixed ConvRot;
- DynTime/sQKV.

Hugging Face сейчас показывает десятки H3-связанных community-репозиторий, многие из которых обновлялись в последние 1-2 дня.

Поэтому в нашем гайде дата — обязательная часть информации о каждой сборке.

42 16. Правило для будущих обновлений

При добавлении новой модели записываем:

Название:

Автор:

URL:

Тип:

Дата первого обнаружения:

Дата последнего обновления:

Последний commit:

Размер:

FL2VA:

Ref2VA:

Qwen:

Loader:

Минимальная заявленная VRAM:

Рекомендуемая RAM:

Лицензия:

Статус:

Результат на RTX 3070 Ti:

Если какого-то значения нет в источнике:

не угадываем.

Пишем:

не указано автором

или

не проверено на RTX 3070 Ti.

43 17. Официальные источники

- Comfy-Org MiniMax H3: <https://huggingface.co/Comfy-Org/MiniMax-H3>
- MiniMaxAI MiniMax H3: <https://huggingface.co/MiniMaxAI/MiniMax-H3>
- ComfyUI: <https://github.com/Comfy-Org/ComfyUI>
- I2V workflow: https://github.com/Comfy-Org/workflow_templates/blob/main/templates/video_minimax_h3_i2v.yaml
- T2V workflow: https://github.com/Comfy-Org/workflow_templates/blob/main/templates/video_minimax_h3_t2v.yaml
- Ref2V workflow: https://github.com/Comfy-Org/workflow_templates/blob/main/templates/video_minimax_h3_ref2v.yaml

43.1 Community

- DmitryDB: <https://huggingface.co/DmitryDB/MiniMax-H3-ComfyUI-Quants>
 - Merserk: <https://huggingface.co/Merserk/MiniMax-H3-INT4-ConvRot>
 - Abiray NVFP4/INT4/INT8: <https://huggingface.co/Abiray/Minimax-H3-nvfp4-INT4-INT8-Convrot>
 - starsfriday W4A8: <https://huggingface.co/starsfriday/MiniMax-H3-w4a8>
 - molbal GGUF: <https://huggingface.co/molbal/MiniMax-H3-GGUF>
 - leejet GGUF: <https://huggingface.co/leejet/MiniMax-H3-GGUF>
 - realrebelai GGUFs: https://huggingface.co/realrebelai/MiniMax-H3_GGUFs
 - vantagewithai GGUF: <https://huggingface.co/vantagewithai/MiniMax-H3-comfyUI-GGUF>
-

44 18. Важное уточнение про «все модели»

На 19.08.2026 список H3 уже настолько быстро меняется, что нельзя честно утверждать, будто этот файл содержит абсолютно каждый опубликованный community-файл.

Зато теперь это **актуальная карта основных веток**, которую можно обновлять.

Перед каждым большим релизом гайда повторяем поиск и обновляем колонку даты/commit.

TBD означает: не угадываем; измеряем.


45 04 — Workflow: I2V, T2V, First/Last Frame и Ref2VA

45.1 1. Выбор режима

Режим	Что даём	Контроль персонажа	Приоритет
T2VA	текст	низкий	4
I2V / FL2VA	картинка + текст	высокий	1
First + Last Frame	2 картинки + текст	очень высокий для начала/конца	2
Ref2VA	изображения/видео/аудио + текст	высокий/очень высокий	3

Официальные workflow: I2V, T2V и R2V.

46 2. I2V — основной pipeline



Для VN это основной путь, потому что персонаж уже создан в 3D.

47 3. Как подготовить исходный render

Лучший стартовый render:

- финальное лицо уже готово;
- глаза хорошо видны;
- нет сильного motion blur;
- нет экстремально мелких деталей;
- персонаж занимает разумную часть кадра;
- освещение стабильное;
- фон не перегружен.

Не начинай с групповой сцены.

48 4. Prompt для I2V

Структура:

[SHOT]
Cinematic medium shot of [subject] in [location].

[ACTION]
The subject slowly [one main action].

[CAMERA]
The camera [one camera movement].

[SECONDARY MOTION]
Hair and clothing move subtly and naturally.

[AUDIO]
Describe simple environmental sound.

Главное правило первого теста:

одно главное действие + одно движение камеры.

49 5. Хороший первый пример

Cinematic medium shot of a woman standing in an elegant modern bedroom at night.
She slowly turns her head toward the camera.
Her hair and clothing move subtly and naturally.
The camera performs a very slow cinematic push-in.
Warm practical lighting with a soft cool rim light from the window.
Quiet bedroom ambience and subtle fabric movement.

50 6. Почему не надо писать слишком длинный prompt

Слишком много требований одновременно увеличивает вероятность конфликтов.

Плохой первый тест:

turns + walks + sits + touches hair + changes expression + camera orbit + zoom + lighting c

Хороший:

slowly turns her head toward the camera
+ slow camera push-in

После стабильного результата усложняем.

51 7. First Frame

First Frame задаёт стартовое состояние.

Для VN:

готовый 3D render → First Frame → движение.

Это наш базовый production-подход.

52 8. Last Frame

Last Frame задаёт желаемый финал.

Например:

Frame A: персонаж стоит

Frame B: персонаж уже сидит

H3 строит переход.

Начинаем с небольшого различия между кадрами. Большой скачок позы может быть сложнее.

53 9. First + Last Frame

Очень интересный режим для VN.

Используем, когда хотим получить не случайное движение, а переход между двумя заранее подготовленными состояниями.

54 10. T2VA

Prompt

↓

H3 FL2VA

↓

Video + Audio

Без изображения FL2VA workflow может использоваться как text-to-video/text-to-audio.

T2V полезен для:

- establishing shots;
- интерьеров;
- природы;
- фонов;
- второстепенных кадров.

Для постоянных персонажей предпочитаем I2V/Ref2VA.

55 11. Ref2VA

Ref2VA — отдельный checkpoint и отдельный workflow.

Актуальная документация позволяет использовать несколько типов референсов. В workflow описаны изображения, видео и отдельные аудиореференсы.

55.0.1 Пример логики

Image 1 = identity

Image 2 = clothing

Image 3 = environment

Video 1 = motion/camera reference

Audio 1 = voice/sound reference

↓

Ref2VA

↓

new shot

56 12. Роли референсов

В prompt явно описывай роль каждого reference.

Пример:

Use <Picture 1> as the main character identity.

Use <Picture 2> as the clothing reference.

Use <Picture 3> as the environment reference.

Create a cinematic medium shot of the character slowly turning toward the camera.

Не заставляй модель угадывать, зачем ты дал картинку.

57 13. ref_image_size

Если конкретный Ref2VA workflow предлагает:

match — начинаем с него на 8 GB.

max — тестируем потом, если нужна дополнительная детализация/идентичность.

В документации Ref2VA больший reference size может увеличить вычислительную стоимость.

58 14. Sampler / Scheduler

Не переносим настройки одного workflow в другой.

Сначала оставляем sampler/scheduler из официального шаблона.

В Ref2VA документация отдельно отмечает res_multistep и предпочтение beta/normal scheduler для некоторых reference-heavy prompts.

59 15. Аудио

НЗ — видео+аудио модель.

Поэтому prompt может содержать звук:

quiet bedroom ambience

soft fabric movement

distant city noise

subtle footsteps

Не обязательно добавлять звук в каждый prompt, но для production-клипов лучше сразу учитывать audio design.

60 16. Разрешение

Официальные workflow задают свои допустимые размеры и сетку. Не надо вручную вводить произвольное разрешение, если workflow его округляет.

На 3070 Ti:

1. стартовый размер из workflow;

2. проверить VRAM;
 3. затем поднять разрешение;
 4. потом отдельно увеличить длительность.
-

61 17. Длительность

H3 работает с допустимой сеткой кадров, поэтому введённые секунды могут преобразовываться workflow в ближайшее допустимое число кадров.

Не пугайся небольшого расхождения между введённой длительностью и фактическим числом кадров.

62 18. Настройки каждой quant разные

Это принципиально.

Official INT8 → официальный loader/settings

INT4 → настройки конкретного INT4

GGUF Q4 → GGUF loader/settings

W4A8 → W4A8 loader/settings

SVDQuant → SVDQuant loader/settings

Нельзя сделать один универсальный preset и считать его оптимальным для всех.

63 19. Production workflow №1 — персонаж

3D render

↓

I2V / FL2VA

↓

4–8 sec

↓

24 fps

↓

H3 audio

↓

MP4

64 20. Production workflow №2 — identity-heavy

Character references

+

Environment references

+

Optional motion/video

↓

Ref2VA

↓

Video + Audio

65 21. Production workflow №3 — переход

First Frame
+
Last Frame
↓
FL2VA
↓
transition shot

66 22. Production workflow №4 — фон

Text
↓
T2VA
↓
background / establishing shot

67 23. Рекомендуемая библиотека preset

После тестов сохраняем:

VN_I2V_FAST.json
VN_I2V_BALANCED.json
VN_I2V_QUALITY.json
VN_FIRST_LAST_FRAME.json
VN_REF2VA_CHARACTER.json
VN_REF2VA_SCENE.json
VN_T2VA_BACKGROUND.json

В каждом preset записываем H3/Qwen/commit и дату.

68 05 — Экспериментальная лаборатория

68.1 Цель

Не угадывать, какая сборка лучше, а получить реальные данные на **RTX 3070 Ti 8 GB + 64 GB RAM**.

69 1. Золотое правило

В одном эксперименте меняем **один главный параметр**.

Фиксируем:

- исходную картинку;
 - prompt;
 - seed;
 - resolution;
 - duration;
 - steps;
 - sampler;
 - scheduler;
 - post-processing.
-

70 2. Qwen 8-bit vs 4-bit

Сначала фиксируем H3.

H3 = одинаковый

Image = одинаковая

Prompt = одинаковый

Seed = одинаковый

Resolution = одинаковая

Duration = одинаковая

Steps = одинаковые

Qwen 8-bit → A

Qwen 4-bit → B

Сравниваем:

- prompt adherence;
- лицо;
- identity;
- движение;
- время;
- VRAM;
- RAM.

Если разница минимальна — выбираем 4-bit ради памяти.

71 3. H3: INT8 → W4 → INT4

После выбора Qwen:

Official INT8

↓

W4

↓
INT4

У каждой модели свой loader и свои оптимальные настройки.

72 4. INT4Q / INT4BQ

Эти варианты считаем **отдельными сборками**, даже если оба называются INT4.

Для каждого записываем:

Repository:
Commit:
File:
File size:
Loader:
ComfyUI:
PyTorch:
CUDA:
Workflow:
Requirements:

73 5. W4A8

Источник:

<https://huggingface.co/starsfriday/MiniMax-H3-w4a8>

Loader:

<https://github.com/starsFriday/ComfyUI-W4A8-Loader>

Это экспериментальный mixed-precision путь. Автор требует специальный loader/comfy-kitchen.

На Windows его installer не является нашим базовым путём. Если понадобится, сначала создаём отдельную экспериментальную среду.

74 6. SVDQuant

Источник:

<https://huggingface.co/Aero-Ex/MiniMax-H3-SVDQuant>

Интересен из-за небольшого checkpoint (~11.1 GB для заявленного rank-64 варианта) и W4A4/SVDQuant подхода. Автор также описывает activation-aware режим.

Для Ampere это один из наиболее интересных экспериментов после обычного INT4.

75 7. GGUF

Тестируем отдельно:

Q4
Q5
Q8

Q2/Q3 можно попробовать, если они реально доступны в конкретном актуальном H3 hero.
Не считаем Q4 автоматически равным W4.
Например, molbal указывает FL2VA Q4_0 11.4 GB и отдельные требования для Q8_CR/U16G.

76 8. Turbo LoRA

Turbo LoRA — не базовая quant.

Сначала получаем baseline без LoRA.

Затем:

Baseline

↓

Turbo LoRA

↓

сравнение качества/времени

Так мы понимаем, сколько скорости получаем ценой качества.

77 9. DynTime / sQKV

Community DynTime/sQKV — отдельная экспериментальная линия.

Не смешивать её benchmark с обычными INT4/W4.

Сначала проверяем запуск, потом качество и время.

78 10. Тест идентичности

Один render.

Prompt:

The character slowly turns her head toward the camera.
Keep the same identity, hairstyle, clothing and facial features.
Subtle breathing and natural hair movement.
Slow cinematic camera push-in.

Оцениваем 0-3:

- лицо;
 - волосы;
 - одежда;
 - тело;
 - движение;
 - камера.
-

79 11. Тест сложного движения

После простого head turn:

1. head turn;
2. hand movement;
3. walking;
4. camera movement;

5. combined action.

Если модель провалилась на пункте 2, не тратим время на сложный пункт 5.

80 12. Тест длинного видео

После стабильных 4–5 секунд:

5 sec

↓

8 sec

↓

10 sec

↓

12 sec

↓

15 sec

Записываем время и стабильность отдельно.

81 13. Тест разрешения

Длительность фиксируем:

5 sec / low

5 sec / native workflow

5 sec / higher

Только после этого тестируем более длинный ролик.

82 14. Система оценки

Параметр	0	1	2	3
Лицо	ломается	сильно меняется	в основном стабильно	очень стабильно
Одежда	ломается	часто меняется	в основном стабильна	стабильна
Волосы	артефакты	нестабильны	приемлемо	стабильно
Движение	плохое	заметные артефакты	хорошее	очень хорошее
Камера	ломается	дёргается	приемлемо	кинематографично
Фон	ломается	меняется	приемлемо	стабильно

83 15. PASS/FAIL

- PASS — запускается;
- PASS-GOOD — хорошее качество;
- PASS-SLOW — работает, но очень медленно;
- OOM — память;
- ERROR — техническая ошибка;
- BAD-QUALITY — технически работает, но результат плохой;

- EXPERIMENTAL — пока недостаточно тестов.
-

84 16. Три production-профиля

84.0.1 FAST

Минимальное время.

84.0.2 BALANCED

Лучшее качество/время.

84.0.3 QUALITY

Самая тяжёлая практически используемая модель.

Отдельно:

84.0.4 EXPERIMENTAL

Новые community сборки.

85 17. Как фиксировать эксперимент

```
experiments/  
├── 2026-08-19_INT4-vs-INT8/  
│   ├── prompt.txt  
│   ├── settings.txt  
│   ├── input.png  
│   ├── output_A.mp4  
│   ├── output_B.mp4  
│   └── result.md
```

В settings.txt обязательно хранить commit модели.

86 18. Почему один ролик недостаточен

Случайность может сделать один результат красивее.

Для первичной оценки — минимум 3 prompts.

Для выбора production-модели — 5-10 разных сцен.

87 19. Финальный вопрос лаборатории

Нам нужен не победитель по размеру файла.

Нам нужен ответ:

какой H3 + Qwen + workflow + настройки дают лучший результат на RTX 3070 Ti 8 GB за приемлемое время?

88 06 — Полный benchmark на RTX 3070 Ti 8 GB + 64 GB RAM

88.1 Цель

Получить реальные цифры именно на твоём ПК. Чужие результаты — только ориентир.

89 1. Карточка каждого теста

Date:
ComfyUI:
Python:
PyTorch:
CUDA:
GPU:
VRAM:
RAM:
H3 repository:
H3 commit:
H3 file:
H3 format:
Qwen repository:
Qwen commit:
Qwen file:
Qwen format:
Loader repository:
Loader commit:
Workflow:
Workflow commit:
Mode:
Resolution:
Frames:
FPS:
Duration:
Steps:
Sampler:
Scheduler:
Seed:
Offload:
Load time:
Generation time:
Total wall time:
Peak VRAM:
Peak RAM:
Result:
Notes:

90 2. Почему нельзя копировать чужую скорость

Если автор получил «5 секунд за 1.5 минуты», это не означает, что 3070 Ti получит 90 секунд.

На результат влияют:

- GPU;
- VRAM;
- bandwidth;
- CPU;

- RAM speed;
 - PCIe;
 - CUDA;
 - PyTorch;
 - loader;
 - offload;
 - resolution;
 - steps.
-

91 3. A1 — официальный baseline

H3:
minimax_h3_fl2va_pruned_int8_convrot

Qwen:
official H3 encoder

Mode:
I2V

Input:
один 3D render

Duration:
4–5 sec

Seed:
fixed

Цель — первое стабильное видео.

92 4. A2/A3 — Qwen

A2 = Qwen 8-bit
A3 = Qwen 4-bit

Остальные параметры одинаковые.

93 5. B — H3

После выбора Qwen:

Official INT8

↓

W4

↓

INT4

↓

INT4Q

↓

INT4BQ

↓

SVDQuant

↓

W4A8

↓
GGUF

Если вариант несовместим с Windows/8 GB, записываем N/A и причину.

94 6. VRAM

Записываем **peak VRAM**.

Размер файла модели не равен peak VRAM.

Например, W4A8 checkpoint заявлен примерно 12.54 GB, но это размер файла, а не требование 12.54 GB VRAM.

95 7. RAM

При offload RAM может быть очень высокой.

Если приближаемся к 64 GB:

1. остановить тест;
 2. проверить pagefile;
 3. закрыть лишние приложения;
 4. уменьшить resolution/duration;
 5. выбрать более лёгкую quant.
-

96 8. Время

Отдельно:

- **Load time** — загрузка модели;
- **Generation time** — только генерация;
- **Total wall time** — весь процесс.

Для сравнения моделей главным показателем является Generation time.

97 9. Качество 0-10

Параметр	Score
Лицо	/10
Identity	/10
Одежда	/10
Волосы	/10
Руки	/10
Движение	/10
Камера	/10
Фон	/10
Аудио	/10
Overall	/10

98 10. Quality/Time

Вспомогательная метрика:
Quality per minute = Overall / Generation minutes
Она не заменяет визуальную оценку.

99 11. Матрица

Test	H3	Qwen	Mode	Resolution	Sec	Time	VRAM	RAM	Score
A1	INT8	8-bit	I2V	TBD	5	TBD	TBD	TBD	TBD
A2	INT8	4-bit	I2V	TBD	5	TBD	TBD	TBD	TBD
B1	W4	4-bit	I2V	TBD	5	TBD	TBD	TBD	TBD
B2	INT4	4-bit	I2V	TBD	5	TBD	TBD	TBD	TBD
C1	INT4Q	4-bit	I2V	TBD	5	TBD	TBD	TBD	TBD
C2	INT4BQ	4-bit	I2V	TBD	5	TBD	TBD	TBD	TBD
D1	SVDQuant	4-bit	I2V	TBD	5	TBD	TBD	TBD	TBD
D2	W4A8	4-bit	I2V	TBD	5	TBD	TBD	TBD	TBD
E1	GGUF Q4	TBD	I2V	TBD	5	TBD	TBD	TBD	TBD

100 12. Длинные ролики

Только после стабильных 5 секунд:
5 → 8 → 10 → 12 → 15 sec
Для каждого этапа фиксируем время, VRAM, RAM, качество начала/конца и стабильность.

101 13. Разрешение

Длительность фиксируем:
5 sec / low
5 sec / native workflow
5 sec / higher
Только после этого увеличиваем длительность.

102 14. OOM protocol

- При CUDA out of memory:
1. сохранить полный текст ошибки;
 2. записать H3/Qwen commit;
 3. закрыть другие GPU-приложения;
 4. уменьшить resolution;
 5. уменьшить frames/duration;
 6. проверить offload;
 7. перейти на более лёгкий quant.

103 15. Missing model

Проверить:

models/diffusion_models
models/text_encoders
models/vae

и точное имя файла.

104 16. Missing node

Проверить:

- ComfyUI;
- workflow source;
- custom_nodes;
- README конкретного проекта.

Не ставить случайный node pack только по названию ошибки.

105 17. Production-ready

Сборка считается пригодной, если она:

- запускается повторно;
 - не падает случайно;
 - сохраняет персонажа;
 - даёт приемлемое движение;
 - даёт приемлемый звук, если он нужен;
 - имеет зафиксированные версии;
 - имеет понятный workflow;
 - имеет измеренное время.
-

106 18. Финальные профили

106.0.1 FAST

Минимальное время.

106.0.2 BALANCED

Лучший баланс.

106.0.3 QUALITY

Лучшее реально используемое качество.

106.0.4 EXPERIMENTAL

Новые community сборки.

107 19. Production benchmark

Перед окончательным выбором проверяем минимум:

- 5 персонажей;
- 5 сцен;
- 3 типа движения;
- 3 типа камеры;
- несколько prompts.

Если модель хорошо работает только на одной сцене — она не production-ready.

108 07 — Сверка предыдущих чатов: стыковки и несостыковки

Дата сверки: 20.08.2026

108.1 1. Что подтверждается и сохраняется

108.1.1 Железо

- GPU: **NVIDIA RTX 3070 Ti Laptop, 8 GB VRAM.**
- RAM: **64 GB.**
- Стратегия: не гнаться за максимальной скоростью; искать лучшее соотношение **качество / время.**
- Большие модели допускается запускать через RAM/CPU offload, если конкретный loader это поддерживает.

108.1.2 План Qwen

1. сначала проверить **Qwen 8-bit**;
2. затем **Qwen 4-bit**;
3. сравнить качество, скорость и память;
4. выбрать практичный вариант.

108.1.3 План H3

После выбора Qwen тестируем H3 по группам: - INT8; - W4/W8 mixed; - W4; - W4 Offload; - INT4; - INT4Q; - INT4BQ; - W4A8; - затем отдельные experimental/GGUF-пути.

108.1.4 Главный production-режим

Для Visual Novel приоритетом остаётся **I2V**: сначала получить стабильный 3D-рендер персонажа, затем использовать H3 для движения.

Ref2VA рассматривается после успешного базового I2V.

109 2. Несостыковка №1 — «убрать 16 версии»

Фраза была ранее понята как отказ от **16-bit/BF16** вариантов. Практическое правило текущего гайда:

BF16 / 16-bit как основной вариант для нашей 8 GB карты не рассматриваем.

При этом не удаляем упоминания других форматов, если они нужны для понимания экосистемы.

110 3. Несостыковка №2 — ComfyUI 0.28 против H3

В начале пользователь сообщил: - Python 3.13.12; - ComfyUI 0.28.

В чате был установлен ориентир **ComfyUI 0.30.0+** для современных H3 workflow.

Поэтому 0.28 не считаем рабочей базой для первого H3 запуска. Сначала проверяем/обновляем ComfyUI.

При этом конкретный experimental loader может требовать свою версию — его README имеет приоритет.

111 4. Несостыковка №3 — «Qwen 3.6 / 3.8»

Наличие у пользователя каких-то моделей «Qwen 3.6 и 3.8» **не подтверждает**, что установлен нужный H3 encoder.

Для H3 нас интересует конкретно:

Qwen3-VL-32B, H3-compatible encoder.

Обычная Qwen-модель для чата/LLM не считается автоматически совместимой заменой.

112 5. Несостыковка №4 — Qwen и H3

Qwen не является второй видеомоделью и не заменяет MiniMax.

Qwen3-VL-32B

↓

понимает conditioning

↓

MiniMax H3

↓

создаёт видео/аудио

Они могут использоваться в одном workflow.

113 6. Несостыковка №5 — размер файла ≠ необходимая VRAM

Размер checkpoint нельзя напрямую считать требованием VRAM.

На пиковую память влияют: - loader; - quantization; - offload; - activations; - resolution; - frames; - VAE; - одновременно загруженные компоненты.

Поэтому реальные показатели для RTX 3070 Ti получаем только тестом.

114 7. Несостыковка №6 — W4, INT4 и GGUF Q4

Это разные вещи: - **INT4** — общий класс 4-bit представления; - **W4** — конкретная схема 4-bit weights; - **GGUF Q4** — схема внутри GGUF ecosystem.

Одинаковая цифра 4 не означает одинаковое качество, скорость, память или loader.

115 8. Несостыковка №7 — NVFP4

NVFP4 исключён из первого практического прохода на RTX 3070 Ti, но не объявляется невозможным вообще.

Конкретный backend/loader определяет совместимость и эффективность.

116 9. Несостыковка №8 — W4A8

W4A8 нельзя считать обычным W4 checkpoint. Это отдельный experimental pipeline со специальным loader/toolchain.

На Windows требования конкретного loader могут ограничивать использование, поэтому W4A8 ставим только после стабильного baseline.

117 10. Что исправлено в текущем репозитории

- старые удалённые community-файлы не считаем актуальными;
 - при отсутствии v1/v2 фиксируем дату и commit;
 - разделяем официальный baseline и community quant;
 - разделяем safetensors и GGUF;
 - не выдаём размер файла за требование VRAM;
 - не выдаём обычный Qwen за H3 encoder;
 - сначала сравниваем Qwen 8-bit и 4-bit;
 - реальные benchmark-цифры на RTX 3070 Ti не придумываем.
-

118 11. Итоговая согласованная стратегия

```
ComfyUI
↓
проверка версии
↓
VAE
↓
H3-compatible Qwen 8-bit
↓
стабильный H3 baseline
↓
первый I2V
↓
Qwen 4-bit
↓
сравнение 8 vs 4
↓
выбор Qwen
↓
H3 INT8 / W4 / INT4
↓
W4 Offload
↓
Ref2VA
↓
W4A8 / SVDQuant / GGUF / Turbo LoRA / DynTime
```

118.1 Финальный критерий

Лучшее качество за приемлемое время на RTX 3070 Ti 8 GB + 64 GB RAM.

119 12. Что пока нельзя утверждать без реального теста

Не утверждаем заранее: - точное время генерации на 3070 Ti; - точное пиковое VRAM каждой квантизации; - точное качество Qwen 8-bit против 4-bit; - что конкретный experimental loader заработает на Windows; - что конкретный GGUF окажется быстрее safetensors.

Эти значения добавляются после реальных запусков.